

ЛАБОРАТОРНАЯ РАБОТА

Тема: Построение процесса интеллектуального анализа данных в рамках решения задачи кредитного скоринга.

Цель: Получить навыки интеллектуального анализа данных при решении задачи кредитного скоринга с использованием технологий распределенной обработки больших данных Apache Spark.

Решаемые задачи:

1. Построение физической модели данных на основе информации об источниках данных.
2. Построение хранилища данных.
3. Разработка процессов обновления распределенных данных при использовании Apache Spark.
4. Проведение первичного анализа данных при использовании Apache Spark.
5. Предобработка данных при использовании Apache Spark.
6. Обучение модели машинного обучения на распределенных данных для решения задачи кредитного скоринга.

ОПИСАНИЕ ВХОДНЫХ ДАННЫХ

Даны 3 источника данных, которые содержат информацию о клиенте и его транзакционной активности. Ниже приведено описание источников.

Источник 1. Данные о транзакционной активности клиента по дебетовым картам.

Источник содержит данные о транзакционной активности клиента по дебетовым картам за отчетный месяц.

1.1 DDL источника.

```
CREATE TABLE `lab_1.deb_cards_info`(  
    client_id int,  
    onl_bank_active_1m_nflag int,  
    auto_pay_active_qty int,  
    cl_income_1m_amt decimal(18, 2),  
    dep_acc_1st_open_dt timestamp,  
    wdr_cash_6m_amt decimal (18, 2),  
    cash_op_6m_amt decimal(18, 2),  
    cash_3m_qty decimal(18, 2),  
    lst_balance_amt decimal(18, 2),  
    card_active_1m_nflag decimal(18, 2),  
    row_update_dtime timestamp,
```

```

row_loading_id bigint,
row_hash_val string)
PARTITIONED BY (
report_dt string
)

```

1.2 Описание атрибутов.

Атрибут	Тип данных	Описание
client_id	int	ID клиента
onl_bank_active_1m_nflag	int	Флаг активности клиента в онлайн-банкинге за 1 месяц.
auto_pay_active_qty	int	Количество активных шаблонов "Автоплатеж" за месяц.
cl_income_1m_amt	decimal(18, 2)	Сумма дохода по клиенту за отчетный месяц по дебетовым картам.
dep_acc_1st_open_dt	timestamp	Дата открытия первого депозитного договора клиента.
wdr_cash_6m_amt	decimal(18, 2)	Сумма снятия наличных в рублях за последние 6 месяцев.
cash_op_6m_amt	decimal(18, 2)	Объем в рублях операций за последние 6 месяцев.
cash_3m_qty	decimal(18, 2)	Количество операций за последние 3 месяца
lst_balance_amt	decimal(18, 2)	Баланс последней действующей дебетовой карты.
card_active_1m_nflag	int	Флаг активности по дебетовым картам за 1 месяц
row_update_dtime	timestamp	Дата обновления строки, тех. поле
row_loading_id	bigint	ID загрузки строки, тех. поле
row_hash_val	string	Хеш строки, тех. поле
report_dt	string	Дата публикации данных, тех. поле, по которому секционирована таблица.

1.3 Формат хранения и частота обновления.

Данные хранятся в формате SCD1, обновление происходит 1 раз в конце месяца. При этом при обновлении данных, поле report_dt заполняется последним днем отчетного месяца.

Источник 2. Данные по кредитным картам клиента.

Источник содержит данные о транзакционной активности клиента по кредитным картам за отчетный месяц.

2.1 DDL источника.

```
CREATE TABLE `lab_1.credit_cards_info`(  
    client_id int,  
    client_income_amt decimal(18, 2),  
    oi_total_amt decimal(18, 2),  
    act_pl_os_rub_amt decimal(18, 2),  
    payroll_client_nflag int,  
    inf_payroll_rub_amt decimal (18, 2),  
    legal_entity_amt decimal(18, 2),  
    otf_loan_rub_amt decimal(18, 2),  
    otf_fee_rub_amt decimal(18, 2),  
    inf_transfer_rub_amt decimal(18, 2),  
    cc_ever_nflag int,  
    row_update_dtime timestamp,  
    row_loading_id bigint,  
    row_hash_val string)  
PARTITIONED BY (  
    `report_dt` string  
);
```

2.2 Описание атрибутов.

Атрибут	Тип данных	Описание
client_id	int	ID клиента
client_income_amt	int	Доход клиента по данным от рисков (из заявок). (в источнике за последние 6 месяцев с окончанием _Sum6mnth)
oi_total_amt	int	Сумма общего дохода по клиенту за отчетный месяц по всем кредитам
act_pl_os_rub_amt	decimal(18, 2)	Совокупная задолженность по кредитам наличными

payroll_client_nflag	int	Флаг зарплатного клиента (среднемесячные з/п начисления за 3 мес. хотя бы по одному из счетов > 3000 руб.)
inf_payroll_rub_amt	decimal(18, 2)	Сумма зарплатных начислений по всем счетам клиента за месяц в рублях
legal_entity_amt	decimal(18, 2)	Сумма поступлений от ЮЛ
otf_loan_rub_amt	decimal(18, 2)	Общая сумма списания в погашение кредита по всем картам клиента за месяц в рублях
otf_fee_rub_amt	decimal(18, 2)	Общая сумма списания комиссий по всем картам клиента за месяц в рублях
inf_transfer_rub_amt	decimal(18, 2)	Общая сумма поступлений путем перевода с карты/счета по всем картам клиента за месяц в рублях
cc_ever_nflag	int	Флаг наличия кредитной карты когда-либо
row_update_dtime	timestamp	Дата обновления строки, тех. поле
row_loading_id	bigint	ID загрузки строки, тех. поле
row_hash_val	string	Хеш строки, тех. поле
report_dt	string	Дата публикации данных, тех. поле, по которому секционирована таблица.

2.3 Формат хранения и частота обновления.

Данные хранятся в формате SCD1, обновление происходит 1 раз в конце месяца. При этом при обновлении данных, поле report_dt заполняется последним днем отчетного месяца.

Источник 3. Данные по клиенту, обновляемые раз в день.

3.1 DDL источника.

```
CREATE TABLE lab_1.client_cards_daily (  
    client_id int,  
    srv_mb_nflag int,  
    cc_stoplist tinyint,  
    lne_tot_debt_int_ovrd_rub_amt decimal(18,2),  
    lne_tot_debt_ovrd_rub_amt decimal(18,2),  
    row_update_dtime timestamp,  
    row_loading_id bigint,  
    row_hash_val string,  
    row_actual_from string  
)  
PARTITIONED BY (  
    row_actual_to string  
);
```

3.2 Описание атрибутов.

Атрибут	Тип данных	Описание
client_id	int	ID клиента
srv_mb_nflag	int	Флаг, что у клиента подключен мобильный банк
cc_stoplist	tinyint	Флаг, что клиенту нельзя предлагать кредит
lne_tot_debt_int_ovrd_rub_amt	decimal(18, 2)	Сумма просрочки по процентам по кредитам
lne_tot_debt_ovrd_rub_amt	decimal(18, 2)	Сумма просрочки по основному долгу по кредитам
row_update_dtime	timestamp	Дата обновления строки, тех. поле
row_loading_id	bigint	ID загрузки строки, тех. поле
row_hash_val	string	Хеш строки, тех. поле
row_actual_from	string	Дата начала, с которой строка является актуальной, тех. поле.
row_actual_to	string	Дата, до которой строка является актуальной, техническое поле, по которому секционирована таблица.

3.3 Формат хранения и частота обновления.

Данные хранятся в формате SCD2, обновление происходит 1 раз в день. При обновлении данных старые данные деактуализируются и закрываются вчерашним днем($row_actual_to = < \text{день расчета} > - 1$).

ЗАДАНИЕ 1

На основе информации об источниках построить физическую модель данных, в которой будут отражены:

- 1) Информация обо всех атрибутах клиента, которые несут в себе бизнес-смысл (название, краткое описание, дата обновления, источников и т.д.).
- 2) Информация об источниках (название, краткое описание, частота обновления и т.д.).
- 3) Атрибуты, которые обновляются раз в месяц. При этом формат представления должен быть вертикальным (нормализованным), а формат хранения SCD1.
- 4) Атрибуты, которые обновляются каждый день. При этом формат представления должен быть вертикальным (нормализованным), а формат хранения SCD2.
- 5) Информация об обновлениях сущностей с атрибутами клиента (дата обновления источника, дата обновления сущности по источнику и т. д.).